

Bayesian Inference

Mauricio A. Álvarez PhD,
H.F. Garcia C. Guarnizo (TA)



Universidad Tecnológica de Pereira, Pereira, Colombia

1 Bayes: conceptos básicos



1 Bayes: conceptos básicos




Bayes

El lenguaje de la incertidumbre.

- Teoría de probabilidad
- Específicamente *Bayesian probability theory* (1750!)

Cuando se aplica en ciencias de datos ...

- Bayesian modelling



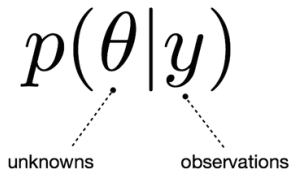
- Construido sobre sólidos fundamentos matemáticos.
- Ortogonal al deep learning...



Que es el análisis estadístico Bayesiano?

- Un model Bayesiano se describe por parámetros. Su incertidumbre en los parámetros se describe utilizando distribuciones de probabilidad.
- Todos los aspectos derivados de procedimientos Bayesianos se realizan en términos de probabilidades.

Practical methods for making inferences from data using probability models for quantities we observe and about which we wish to learn. – Gelman et al. 2013

$$p(\theta|y)$$


The diagram shows the mathematical expression $p(\theta|y)$ with two dotted lines pointing from the terms below to the variables in the expression. A dotted line points from the word "unknowns" to the parameter θ , and another dotted line points from the word "observations" to the variable y .

unknowns observations



Estadísticas bayesianas vs frecuentistas: ¿Cuál es la diferencia? I

Cualquier paradigma estadístico, bayesiano o de otro tipo, involucra al menos lo siguiente:

- Algunas cantidades desconocidas sobre las cuales estamos interesados en aprender o probar. Llamamos a estos parámetros.
- Algunos datos que se han observado, y con suerte contienen información sobre (1).
- Uno o más modelos que relacionan los datos con los parámetros, y es el instrumento que se utiliza para aprender.



Estadísticas bayesianas vs frecuentistas: ¿Cuál es la diferencia? II

The Frequentist World View

- Los datos que se han observado se consideran aleatorios, porque son realizaciones de procesos aleatorios y, por lo tanto, variarán cada vez que uno vaya a observar el sistema.
- Los parámetros del modelo se consideran fijos. Los valores de los parámetros son desconocidos, pero son fijos, por lo que los condicionamos.



Estadísticas bayesianas vs frecuentistas: ¿Cuál es la diferencia? III

The Bayesian World View

- Los datos se consideran **fijos**. Solían ser aleatorios, pero una vez se procesan no cambian.
- Los parámetros del modelo en sí pueden no ser aleatorios
- Se utilizan distribuciones de probabilidad para describir su incertidumbre en los valores de los parámetros (i.e. se consideran aleatorios).
- En algunos casos, es útil considerar los parámetros como muestras de distribuciones de probabilidad.



- Un modelo describe datos que se podrían observar desde un sistema.
- Si usamos las matemáticas de la teoría de la probabilidad para expresar todas las formas de incertidumbre y ruido asociadas con nuestro modelo ...
- ... entonces la **probabilidad inversa** es decir, se *infiere de las observaciones a los parámetros*, o de los efectos a las causas.



Bayes' Formula

La fórmula de Bayes es el **único estimador** que los Bayesianos necesitan para obtener estimaciones de cantidades desconocidas que nos interesan.

$$\text{Pr}(\theta|y) = \frac{\text{Pr}(y|\theta)\text{Pr}(\theta)}{\text{Pr}(y)}$$

Diagram illustrating Bayes' Formula with labels:

- Posterior Probability (points to $\text{Pr}(\theta|y)$)
- Likelihood of Observations (points to $\text{Pr}(y|\theta)$)
- Prior Probability (points to $\text{Pr}(\theta)$)
- Normalizing Constant (points to $\text{Pr}(y)$)



Ejemplo: Genetic probabilities I

- Pongamos la inferencia Bayesiana en acción usando un ejemplo muy simple. Mostraremos cómo se pueden utilizar los datos para actualizar nuestra creencia en hipótesis en competencia:
 - La hemofilia es un trastorno genético poco común que afecta la capacidad de los factores de coagulación del cuerpo para coagular la sangre en respuesta a vasos sanguíneos rotos.
 - La enfermedad es un rasgo recesivo ligado al gen X, lo que significa que solo hay una copia del gen en los hombres, pero dos en las mujeres, y el rasgo puede ser enmascarado por el alelo dominante del gen.
 - Esto implica que los hombres con 1 gen están afectados, mientras que las mujeres con 1 gen no se ven afectadas, pero sí son portadoras de la enfermedad.
 - Tener 2 copias de la enfermedad es fatal, por lo que este genotipo no existe en la población.

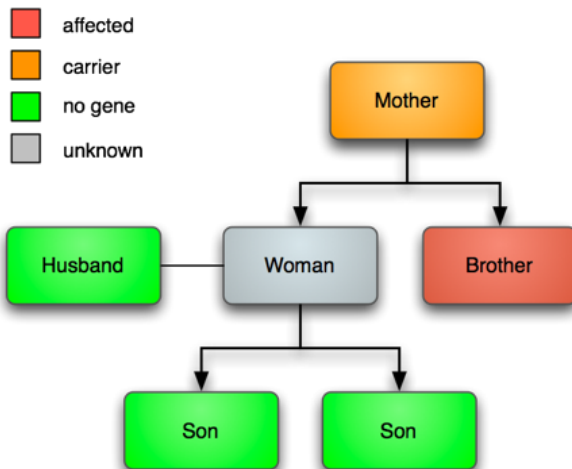


Ejemplo: Genetic probabilities II

- En este ejemplo, consideraremos a una mujer cuya madre es portadora (porque su hermano está afectado) y que se casa con un hombre no afectado.
- Observemos ahora algunos datos: la mujer tiene dos hijos consecutivos (no mellizos) que no se ven afectados. Estamos interesados en determinar **si la mujer es portadora**.



Ejemplo: Genetic probabilities III



Ejemplo: Genetic probabilities IV

Probability model

La cantidad desconocida de interés es simplemente una variable indicadora W que es igual a 1 si la mujer está afectada y cero si no lo está. Nos interesa la probabilidad de que la variable sea igual a uno, dado lo que hemos observado.

$$Pr(W = 1 | s_1 = 0, s_2 = 0)$$

- Nuestra información previa (*prior*) se basa en lo que sabemos sobre la ascendencia de la mujer: su madre era portadora.
- Por lo tanto, el anterior es $Pr(W = 1) = 0.5$. Otra forma de expresar esto es en términos de probabilidades previas, o:

$$O(W = 1) = \frac{Pr(W = 1)}{Pr(W = 0)} = 1$$



Ejemplo: Genetic probabilities V

- Ahora para la *likelihood*: la forma de esta función es:

$$L(W|s_1 = 0, s_2 = 0)$$

- Podemos calcular la probabilidad de observar los datos para cualquier valor pasado para el parámetro.
- Aquí, la probabilidad toma solo dos valores posibles:

$$L(W = 1|s_1 = 0, s_2 = 0) = (0.5)(0.5) = 0.25$$

$$L(W = 0|s_1 = 0, s_2 = 0) = (1)(1) = 1$$



Ejemplo: Genetic probabilities VI

- Con todas las piezas en su lugar, ahora podemos aplicar la fórmula de Bayes para calcular la probabilidad posterior de que la mujer sea portadora:

$$\begin{aligned}Pr(W=1|s_1=0,s_2=0) &= \frac{L(W=1|s_1=0,s_2=0)Pr(W=1)}{L(W=1|s_1=0,s_2=0)Pr(W=1)+L(W=0|s_1=0,s_2=0)Pr(W=0)} \\&= \frac{(0.25)(0.5)}{(0.25)(0.5) + (1)(0.5)} \\&= 0.2\end{aligned}$$

- Por lo tanto, hay una probabilidad de 0.2 de que la mujer sea portadora.
- Ahora, ¿qué pasa si la mujer tiene un tercer hijo no afectado? ¿Cuál es nuestra estimación de su probabilidad de ser portadora entonces?



Ejemplo: Genetic probabilities VII

- Simplemente asignamos el análisis posterior del anterior al anterior prior para el nuevo análisis, y procedemos como antes:

$$= 0.1111111111111112$$

Por lo tanto, observar a un tercer niño no afectado ha reducido aún más nuestra creencia de que la madre es portadora



Bayesian Conjugate Priors

https://en.wikipedia.org/wiki/Conjugate_prior



LAB: Bayesian Inference

